Penyiapan Ekosistem Minilab Big Data untuk Sumber Daya Lokal Terbatas

Mensimulasikan arsitektur big data secara realistis dengan sumber daya terbatas — pendekatan modular untuk pembelajaran yang efektif dan efisien.

AKADEMIK · PRAKTIS · MODULAR

Made with GAMMA

Mengapa Laptop Menjadi Tantangan?

Konteks Masalah

Mahasiswa umumnya hanya memiliki laptop 8 GB RAM. Full Hadoop stack terlalu berat, setup kompleks, dan berisiko mengalihkan fokus dari belajar ke troubleshooting.

Solusi yang Realistis

Minilab ini **bukan** membangun cluster produksi — melainkan mensimulasikan **pola arsitektur inti big data** secara hemat sumber daya, tetap akademis, dan mudah diimplementasikan.

Made with GAMMA

Tujuan & Prinsip Desain Minilab

Simulasi Arsitektur

Mensimulasikan ingestion, storage, processing, dan analytics dalam satu ekosistem terpadu

Hemat Resource

Setiap komponen dipilih untuk efisiensi memori tanpa mengorbankan nilai edukasi

Modular

Arsitektur mudah diajarkan, dikembangkan, dan disesuaikan secara bertahap

Fokus Belajar

Mahasiswa fokus pada konsep dan pipeline, bukan troubleshooting infrastruktur

Made with GAMMA

Stack yang Direkomendasikan

Kombinasi komponen ringan yang mampu mensimulasikan seluruh pipeline big data.

🗄️ Sumber Data

PostgreSQL / MySQL sebagai RDBMS, file CSV / XLSX sebagai sumber dataset tambahan

⚙️ Ingestion Layer

Python scripts, Pandas, SQLAlchemy untuk RDBMS, OpenPyXL untuk file Excel

🪣 Storage

MinIO sebagai object storage / data lake — lebih ringan dari full Hadoop HDFS

⚡ Processing & Analytics

Apache Spark **local mode**, PySpark, Spark SQL, Spark MLlib untuk clustering & klasifikasi

📓 Workspace

Jupyter Notebook / JupyterLab sebagai antarmuka interaktif seluruh pipeline

Hadoop full stack dilewati karena terlalu berat (~4–6 GB hanya untuk infrastruktur), setup kompleks, dan kurang relevan sebagai baseline pembelajaran.

Made with GAMMA

C1 — System Context Diagram

Gambaran level tertinggi: siapa yang berinteraksi dengan sistem minilab dan dari mana data berasal.

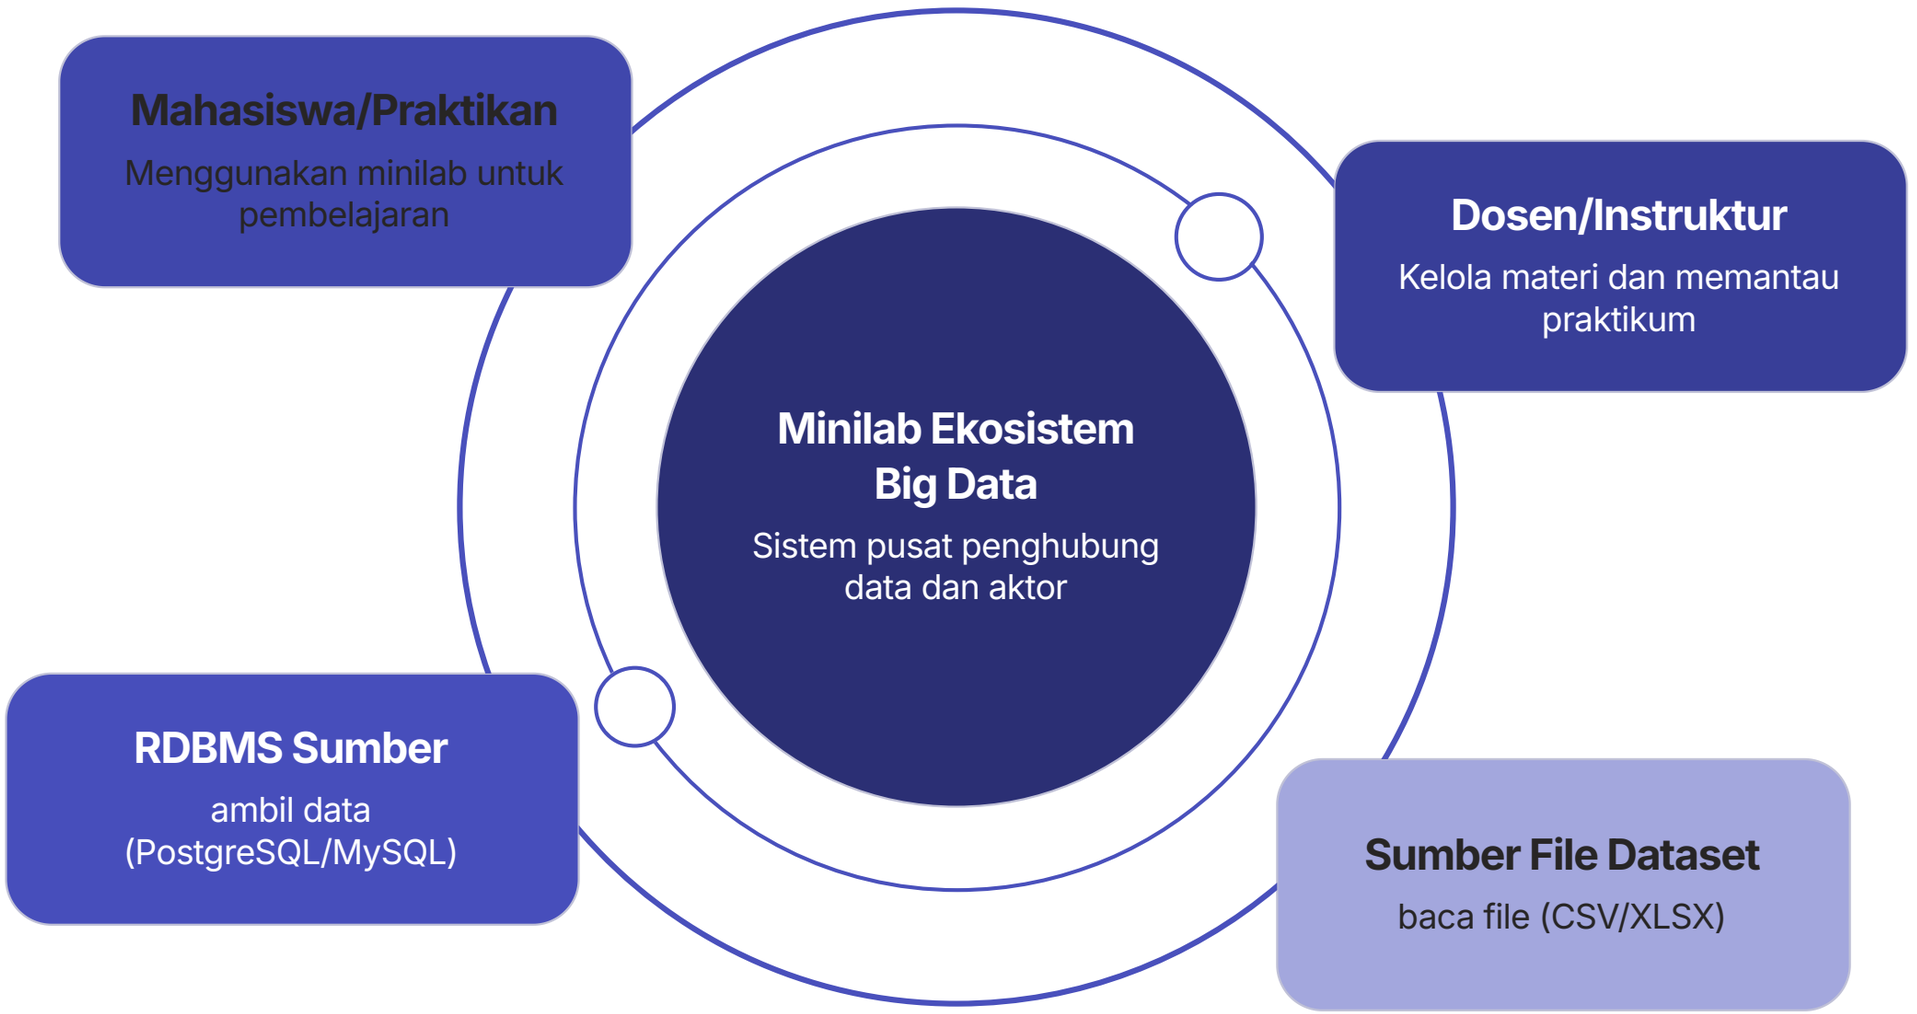

Minilab berfungsi sebagai sistem pusat yang menghubungkan sumber data eksternal dengan aktivitas praktikum mahasiswa di bawah bimbingan instruktur.

Made with GAMMA

C2 — Container Diagram

Empat container internal yang membentuk ekosistem minilab dan bagaimana mereka saling terhubung.

Data mengalir dari sumber eksternal melalui ingestion ke MinIO, lalu Spark membaca, memproses, dan mengembalikan hasilnya ke storage yang sama.

Made with GAMMA

C3 — Ingestion & Preparation Module

Komponen Internal

01

Ingestion Orchestrator

Koordinasi seluruh alur ingestion

02

RDBMS Extractor & File Reader

Ambil data dari PostgreSQL/MySQL dan baca CSV/XLSX

03

Validator & Standardizer

Periksa skema, tipe data, dan standarisasi format

04

Format Converter & Storage Writer

Konversi ke Parquet/CSV, tulis ke MinIO (zona **raw/bronze**)

05

Metadata Logger

Catat log ingestion untuk traceability

Catatan Desain

Modul ini dirancang **modular tanpa Airflow** di tahap awal — cukup dengan Python scripting biasa.

Setiap komponen dapat dikembangkan secara mandiri sesuai kebutuhan praktikum yang lebih lanjut.

Made with GAMMA

C3 — Spark Processing & Analytics Engine

Pipeline end-to-end dari pembacaan data lake hingga output model machine learning.

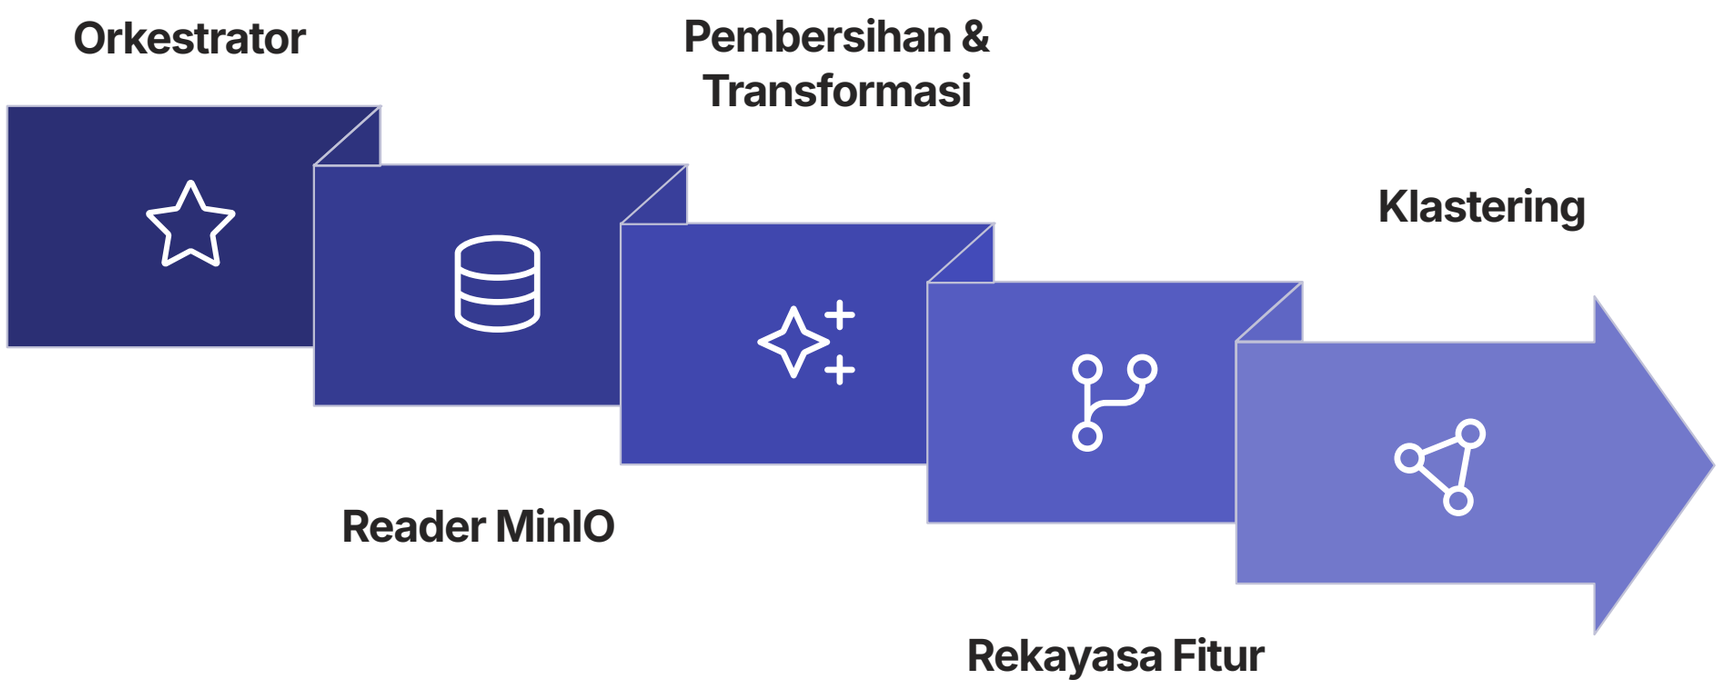

Analytics bukan sekadar training model — ini adalah pipeline data end-to-end yang mencakup pembersihan, rekayasa fitur, pemodelan, evaluasi, hingga penyimpanan hasil.

Made with GAMMA

Deployment Ringan & Alokasi Resource

Strategi Deployment

→ **PostgreSQL / MySQL**

Via Docker — isolasi bersih, mudah di-reset

→ **MinIO**

Via Docker — UI web tersedia di port 9001

→ **JupyterLab + Spark Local**

Di host / virtualenv — lebih ringan dari container

Estimasi Alokasi RAM

512MB

PostgreSQL/MySQL

512MB

MinIO

3GB

Spark Local

4GB

Sisa OS + Jupyter + Browser

Made with GAMMA

Use Case Praktikum & Struktur Data Lake

Skenario Praktikum

1 Ingestion

Tarik data dari PostgreSQL/MySQL dan CSV/XLSX ke MinIO zona **raw (bronze)**

2 Transformasi

Bersihkan dan olah data dengan Spark SQL ke zona **processed (silver)**

3 Clustering

Segmentasi pelanggan dengan KMeans MLlib

4 Klasifikasi

Prediksi churn/risiko dengan Logistic Regression atau Random Forest

Struktur Data Lake di MinIO

🥉 raw/ (Bronze)

Data mentah langsung dari sumber

🥈 processed/ (Silver)

Data bersih hasil transformasi Spark

🥇 feature_store/ (Gold)

Fitur siap pakai untuk machine learning

📤 output/

Hasil model, prediksi, dan laporan

Made with GAMMA